

Clasificación de imágenes para la detección de puntos críticos generados por la acumulación de residuos contaminantes.

IA2 2022-1.

Neider Smith Narvaez Carvajal – 2170128.

Estudiante de Ing. de Sistemas.

Profesor:

Fabio Martínez Carrillo





Atención a los puntos críticos de la ciudad

La acumulación de basuras en distintas zonas de la ciudad generan puntos críticos que deben ser atendidos por las empresas prestadoras del servicio de recolección.





2. Motivación

¡Una ciudad más limpia !

Actualmente, con el objetivo de aportar al mejoramiento de las calles de nuestra ciudad, encontramos en la inteligencia artificial una oportunidad de aportar a la rápida detección de puntos críticos de contaminación para actuar rápidamente en conjunto con la compañía prestadora del servicio de recolección.



Planteamiento del problema:

¿Cómo implementar **redes neuronales convolucionales** para la clasificación de imágenes con o en ausencia de acumulación de residuos contaminantes?



3. Objetivos del proyecto

1. 

Identificar un **dataset**

2. 

Procesar las imágenes del data set.

3. 

Implementar red neuronal convolucional para clasificar las imágenes procesadas.



4. 

Documentar, estudiar e implementar métricas de precisión y error, para **evaluar los resultados obtenidos** con el método de clasificación implementado.



4. Propuesta


1.

Procesamiento de imágenes.




2.

Clasificación con la red neuronal ResNet50V2



3.

Estudio de métricas de evaluación.



5. Resultados Obtenidos

DataSet 1:

Garbage

<https://www.kaggle.com/datasets/apremeyan/garbage/metadata>

Contenido

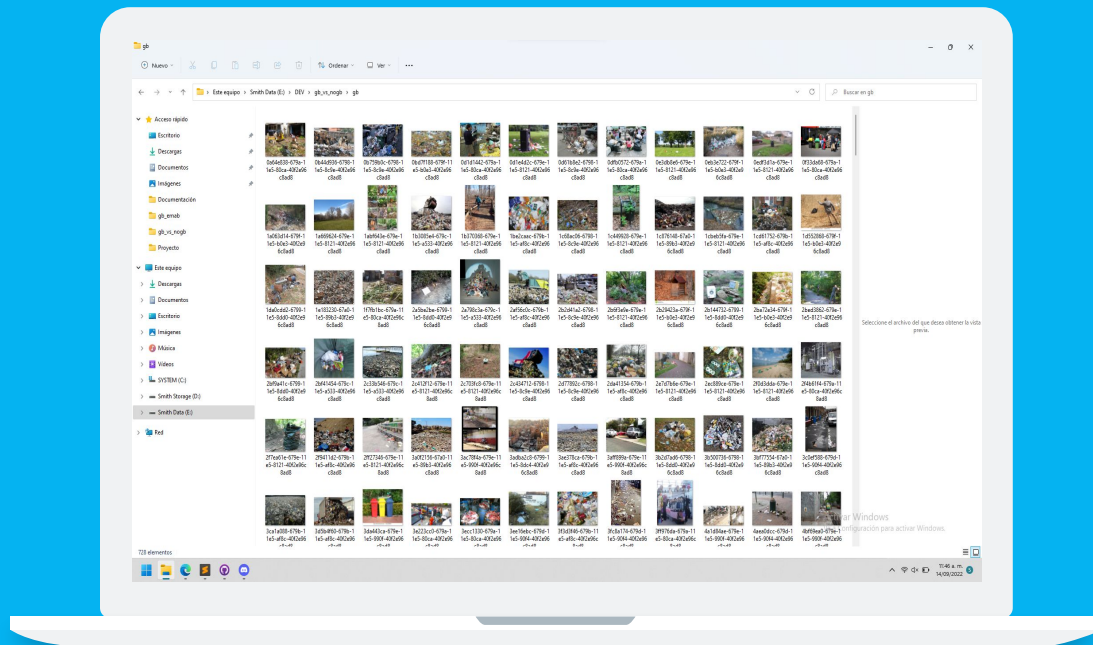
Este dataset contiene más de 2000 imágenes clasificadas entre imágenes con residuos contaminantes de diferentes categorías e imágenes sin residuos



License CCO: Public Domain



Storage 3 GB



DataSet 2:

Imágenes EMAB

https://github.com/NeiderSmith/gb_vs_nogb/tree/main/gb_emab

Contenido

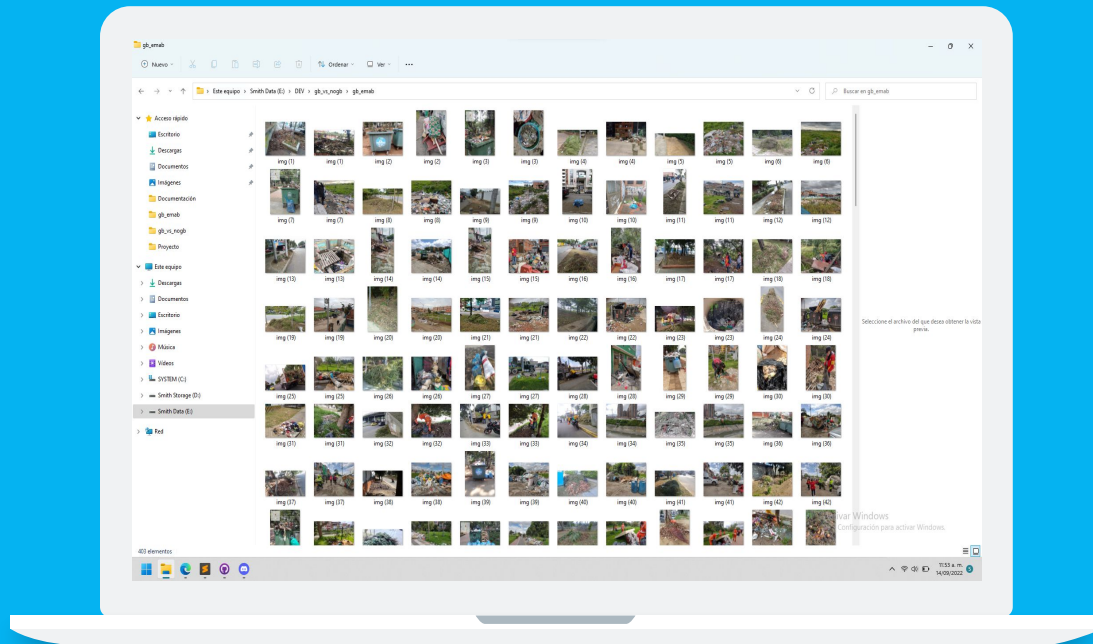
Este dataset contiene más de 403 imágenes de la categoría imagen con residuos contaminantes.



License CCO: Public Domain



Storage 315 MB





Implementación CNN



Hyperparameters

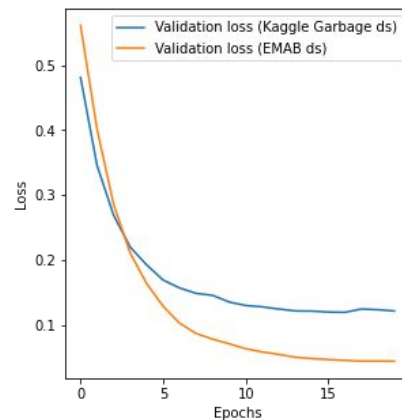

Optimizador	Learning rate	Images input size	Bach size	Capa inicial de reentrenamiento	Parámetros entrenables	Imágenes de entrenamiento (train)	Imágenes de validación (validation)	Número de épocas
Adam	0.00001	299x299 píxeles	32	Toda la red	23.564.800	1189 928	298 233	20



5. Resultados Obtenidos

Se creó un modelo base y se entrenó en dos casos con cada uno de los datasets propuestos. Los resultados para las métricas de evaluación según el dataset fueron:

- Garbage
 - Train acc = 99%
 - Train loss = 0.0105
 - Validation acc = 95.3%
 - Validation loss = 0.1213
- Imagenes EMAB
 - Train acc = 100%
 - Train loss = 0.0098
 - Validation acc = 98.7%
 - Validation loss = 0.0438





6. Conclusiones

Después de haber evaluado el modelo con los diferentes datasets propuesto se pudo concluir que:

- ❖ Al probar el mismo modelo con imágenes mejor seleccionadas (Imágenes EMAB) se logra mejorar en una pequeña medida las métricas de evaluación
- ❖ A pesar de haber entrenado uno de los modelos con una cantidad de imágenes desproporcionadas como lo fue al trabajar solo con las imágenes EMAB, se esperaba encontrar que la predicción tuviera una mayor tendencia a clasificar las imágenes como sin residuos sólidos; a pesar de esto logró superar al modelo entrenado con el dataset Garbage